

# 基於 GAN 校準的半監督學習專案計畫

## 第一部分：專案目標與資料準備

### 1.1 專案目標

本專案的核心目標是：透過一個基於生成對抗網路（GAN）的校準模組，來提升由半監督式學習產生的偽標籤的準確率，從而增強最終物件偵測模型的泛化能力。

### 1.2 資料準備

- **資料來源：**使用約 10,000 張的公開 people 物件資料集(皆含有高品質標註)。
- **資料劃分：**將所有帶有正確標籤的資料，一次性地劃分為三個獨立的子集：
  1. **labeled：**一個較小的、帶有高品質標註的資料集，用於初始模型訓練。
  2. **unlabeled：**一個較大的、僅包含影像的資料集，用於生成偽標籤。
  3. **testset：**一個獨立的測試集，用於每個階段模型進行性能評估。

## 第二部分：四階段循環式訓練流程

### 階段一：監督式預訓練

這是整個流程的起點，旨在訓練出一個強大的基礎「教師模型」。

- **目的：**利用有限的高品質標註資料，訓練出一個性能最優的基礎 YOLO 模型。
- **方法：**使用 labeled 資料集進行標準的監督式訓練。
- **產出：**一個基礎模型權重檔（例如 person\_v1.pt）。

### 階段二：雙軌偽標籤生成

由於在階段三 GAN 訓練時須使用帶有標準答案資料，所以設計了兩條不同的標註方式的軌道，其一是用於 GAN 訓練另一個則是用於最終校準。

- **K-fold 交叉偽標註（用於 GAN 訓練）：**
  - **目的：**為 GAN 提供帶有預測框以及真實框樣本(因須對同組 labeled 樣本進行標註，若採用原教師模型預測可能產生過擬合)。
  - **方法：**採用 K-Fold 交叉驗證。對原始的 labeled 資料集進行

K-Fold 切分，用 K-1 折訓練的模型去預測剩餘的 1 折，從而得到一套覆蓋全部標註資料的(預測框，真實框)數據對。

- **兩階段式偽標註** (用於最終校準):
  - **目的**: 為大量未標註資料生成需要被校準的候選偽標籤。
  - **方法**: 採用兩階段式生成法。
    1. 第一階: 使用階段一產生的教師模型，對 unlabeled 資料集進行預測，僅儲存置信度高於某個閾值的偽標籤。
    2. 第二階: 在第一階篩選出的影像上，使用一個較低的置信度閾值再次預測，以補足遺漏的偵測。

### 階段三: CGAN 訓練

以 pix2pix 作為基礎進行改寫，延續了「局部對抗」優點，但把影像到影像轉換改寫成「影像 → 邊框校正量」的回歸問題，以解決偽標籤定位誤差。

- **目的**: 訓練一個 cGAN 模型，使其學會如何修正偽標籤的定位誤差。
- **生成器 (Generator, G)**:
  - **架構**: 使用 U-Net 為骨幹，保留上下採樣與跳接 (skip connections)。
  - **任務**: 學習預測一個能修正偽標籤的修正向量  $\Delta$ 。
  - **輸入**: 一張經過 Letterbox 處理、大小固定的小影像區塊 (patch)，內容是目標偽標籤框所圈出的影像。
  - **輸出**: 四個連續值，分別代表預測框中心點在水平與垂直方向的偏移量，以及寬、高縮放率 (dx, dy, dw, dh)。
  - **損失函數**: 採用 BCEWithLogits Loss + Smooth-L1 Loss
- **判別器 (Discriminator, D)**:
  - **架構**: 採用 PatchGAN 設計，使用分數圖記錄而非單一分數。
  - **任務**: 學習分辨哪些是 refined patch 或是 GT patch。
  - **輸入**: 同時餵入「預測 patch」與另一張比較 patch (可能是 GT 或經生成器修正後的 refined patch)。
  - **輸出**: 一個 0 到 1 之間的機率值，代表輸入 Patch 的真實度。
  - **損失函數**: 採用 BCEWithLogits Loss
- **對抗訓練流程**:
  - **更新生成器**
    - **目標一**: 說服判別器相信「修正後的 patch」屬於真實 patch。
    - **目標二**: 讓預測偏移量與真實偏移量盡可能接近。
    - 損失函數因此同時包含對抗損失 (生成-對抗) 與回歸損失 (偏移誤差)。
  - **訓練動態裁圖(patch)**

- 生成器輸出偏移量後，將原影像根據偏移量裁切出校準後 patch。
- **更新判別器**
  - **目標一：**分辨數據對是 pred patch + GT patch 或 pred patch + refined patch。
  - **目標二：**保持訓練平衡，使判別器不致過強（導致生成器梯度消失），也不致過弱（無法提供資訊）。

#### 階段四：校準與循環

- **目的：**將兩階段式偽標註生成之偽標籤校準，並加入原資料集循環訓練。
- **方法：**
  1. 使用訓練好的生成器，對兩階段式偽標籤進行校正。
  2. 將校準好的偽標籤，加入到原始的 labeled 資料集中。
  3. 使用這個擴充後獲得更高品質的數據集，返回階段一，重新訓練一個新的、更強大的教師模型。
  4. 重複 階段一 → 階段二 → 階段三 的循環，形成螺旋式增益。

#### 第三部分：成果評估

- **偽標籤品質評估：**在每個循環的階段二結束後，依據真實標籤來計算偽標籤的 TP, FP, FN, Precision, Recall, F1-Score 等指標，以量化偽標籤生成策略的有效性。
- **模型泛化能力評估：**在階段四的每個循環結束後，使用獨立的 testset 來評估當前模型的最終性能，並記錄 mAP50 和 mAP50-95 指標，最終製作成圖表以清晰地展示模型的泛化能力提升。

流程圖：

